



Что скрывают рамановские спектры?

Команда: MISIS Deja Vu



Задача

Разработать алгоритм машинного обучения, который по спектру комбинационного рассеяния определяет, экспериментальную группу образца. Проанализировать спектры и определить информативные спектральные области (пики), которые вносят наибольший вклад в различие между классами.

Данные

Даны рамановские спектры тканей мозга мышей в 3 регионах (cortex, striatum, cerebellum) в двух центрах – при длинах волн 1500 нм и 2900 нм

Preprocessing

Решение

- Интерполяция на опорную сетку модели
- Удаление базовой линии:
 - 1500 нм: arPLS
 - 2900 нм: airPLS
- Нормализация:
 - 1500 нм: MSC
 - 2900 нм: SNV
- 2900 нм: Whitaker-Hayes despike

Эксперименты

- SNIP, Morphological, ASLS (+0)
- Производные (-0.02)
- Фильтр на основе MAD (+0.01)
- 1500 нм: Whitaker-Hayes despike (-0.08)

Modeling

1500 нм

Архитектура: RamanNet 1D

930..1998 cm^{-1} – окно

Идея: делит спектр на сегменты, учит локальные паттерны пиков

2900 нм

Архитектура: Spectral Transformer

2460..3285 cm^{-1} – окно

Идея: patch-представление + self-attention для глобального контекста

Эксперименты

CatBoost / LogReg / SVM (хуже чем DL модели)
Fusion (1500+2900) vs single-window (+0.0245)
Region-aware router (-0.0075)
Hierarchical (region -> class) (-0.0468)

ResNet1D (-0.04)
Inception1D (-0.02)
DRSN1D (-0.03)
EfficientNet1D (-0.01)
RamanNet-SE (+0.011 CV / -0.012 holdout)

Интерпретация

Метод

Обратная задача с L1-регуляризацией (Lasso):

Представляем спектр как взвешенную сумму reference-спектров трех классов

$$\min_{\beta} \sum_{i=1}^n (y_i - x_i^{\top} \beta)^2 + \lambda \|\beta\|_1$$

Анализ весов β показывает вклад каждого класса

Band ANOVA F

$$SS_{\text{between}} = \sum_{k=1}^K n_k (\bar{x}_k - \bar{x})^2$$


$$MS_{\text{between}} = \frac{SS_{\text{between}}}{K - 1}$$

$$SS_{\text{within}} = \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \bar{x}_k)^2$$


$$MS_{\text{within}} = \frac{SS_{\text{within}}}{N - K}$$

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}}$$

Интерпретация



Интерпретация



Валидация

- Group-aware split: спектры одной мыши только в train ИЛИ test
- Battery protocol: не один holdout, а 20+ независимых проверок
- Holdout-triplet: каждая проверка = 3 мыши (control + endo + exo)
- Balanced manifest: квоты по сложным срезам (full-region, cerebellum-stress, mk3-control)
- Region-aware метрики: отдельный F1 по каждому региону
- Worst-slice контроль: модель не проходит, если слаба на сложных срезах
- Dev/Lock split: выбор на dev, независимая проверка на lock

Романов Никита



@KARTASAR

**Голованов
Евгений**



@egolovanov1